UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR
Ingeniería de Sistemas y Computación

Implementación de un Agente Inteligente

FreshCheck-Agent: agente de inspección de calidad de alimentos

Documento de diseño ajustado, selección justificada, desarrollo y pruebas

Presentado por:
Pedro José Castro Blanquicett — T00067714
Entrega individual

Curso: Inteligencia Artificial
Docente: Edwin Puertas, PhD.

Cartagena de Indias, 14 de octubre de 2026

Resumen de la entrega

Este documento corrige y amplía el diseño inicial de FreshCheck-Agent y agrega la selección justificada del agente (Fase 1), la descripción de su implementación (sección 9) y las pruebas contra las medidas de desempeño (Fase 3). El trabajo se realizó de forma individual; por ello se compara FreshCheck-Agent con RetainIQ-Agent, el otro agente que el estudiante diseñó durante el semestre.

Agente implementado: FreshCheck-Agent, agente reflejo basado en modelo, probado sobre un simulador de la línea de empaque (imágenes sintéticas, banda con dinámica y fallas de percepción). **Resultados:** de las seis medidas de desempeño (nueve criterios de aceptación), ocho se cumplieron y uno no: la robustez ante fallas de percepción (M5) alcanzó 98,99 % frente a un umbral de 100 %, debido a que 2 de 15 casos de frutas en contacto no fueron detectados (sección 9.7).

Advertencia de alcance. *Los porcentajes de exactitud corresponden al simulador, cuya dificultad se fijó antes de las pruebas; no son una estimación del desempeño sobre fruta real. La sección 9.8 detalla cómo reentrenar con imágenes reales (FruitVision o fotografías propias).*

Entregable	Ubicación
Documento de diseño ajustado (este PDF)	docs/Informe_FreshCheck_Agent.pdf
Repositorio con README e instrucciones	[PEGAR ENLACE DEL REPOSITORIO]
Plataforma desplegada o video (máx. 20 min)	[PEGAR ENLACE DE LA PLATAFORMA O DEL VIDEO]
Logs de las pruebas	logs/pruebas/*.csv y resultados_resumen.json
Bitácora de uso de IA	docs/Bitacora_uso_IA.pdf

A. Tabla de cambios respecto al diseño inicial

Los cambios provienen de la revisión del propio diseño al implementarlo. La última fila queda reservada para las correcciones que el docente haya señalado en su retroalimentación.

Sección	Qué decía	Qué dice ahora	Por qué cambió
Portada	«Docente: Edwin Puerta»; sin programa académico ni indicación de autoría individual.	Docente: Edwin Puertas, PhD.; programa académico; entrega individual.	Corrección de un error de transcripción y de la identificación de autoría.
2. Tipo de agente	El «modelo interno» era únicamente el modelo de visión entrenado; no se definía estado interno.	Se define un estado interno explícito (ModeloDelMundo): banda de referencia, estado de la cámara, velocidad estimada, contadores por lote.	Un agente basado en modelo debe mantener estado; el diseño no lo especificaba y la implementación lo exige.
3. Ambiente: dinamismo	«Dinámico (entorno objetivo) / Estático (implementación académica)».	«Dinámico», sin doble clasificación: el simulador reproduce banda con deriva de velocidad, plazo de decisión y recarga del desviador.	La guía exige que el simulador respete las propiedades declaradas; una clasificación doble era ambigua.
3. Ambiente: determinismo	Estocástico, justificado de forma general.	Estocástico, con las fuentes de aleatoriedad concretas del simulador (iluminación, ruido, posición, rotación, desenfoque, variedad, velocidad).	Trazabilidad entre diseño e implementación.
5. Entradas	El «metadato de origen y etiqueta de referencia» figuraba como entrada del agente.	Se elimina de las entradas; la etiqueta real queda oculta y se usa solo para evaluar.	Era incoherente con un ambiente parcialmente observable: en operación el agente no conoce la etiqueta.
5. Entradas	Sin señal de disparo ni velocidad de banda (omitidas en la versión adaptada).	Se incluyen disparo, velocidad de banda (encoder con ruido), lote/proveedor e imagen.	La velocidad define el plazo de decisión y el lote permite el reporte por proveedor.
6. Salidas	Clasificación, señal de desvío y registro.	Se agregan la acción REVISION_MANUAL (percepción inválida o frutas en contacto) y la alerta de cámara en falla.	Las condiciones excepcionales de la sección 4 necesitaban una acción segura; sustenta la medida M5.
7. Medidas de desempeño	Viñetas SMART sin fórmulas; «reducción de 30 %» sin línea base; plazo ligado a «tres meses».	Seis medidas (M1 a M6) con fórmula, umbral, estratos y línea base definida (D0 = unidades dañadas sin agente).	La Fase 3 exige fórmula y umbral fijados antes de las pruebas.
7. Alcanzable	«Exactitudes de 87 % a más de 98 %» atribuidas a Ismail y Malik (2022).	Ismail y Malik reportan 99,2 % (manzana) y 98,6 % (banano) con EfficientNet; la visión clásica reporta cerca de 89–92 %.	La cifra de 87 % no corresponde a ese estudio; además, la comparación respalda el umbral y la elección del modelo.
2 y 8. Modelo de visión	«Aprendizaje profundo / modelo de visión por computador» sin precisar el método.	Características de visión clásica y gradient boosting; la CNN queda como trabajo futuro (sección 9.6).	Hardware de un núcleo de CPU, trazabilidad y tiempo de desarrollo disponible.
1, 5 y 7. Fuente de datos	Entrenamiento y evaluación con FruitVision, fotografías propias e imágenes de internet.	Entrenamiento y pruebas sobre imágenes sintéticas del simulador; FruitVision y fotos reales quedan como trabajo futuro (script --real-data).	La guía permite un simulador; los datos reales no se integraron y se evita presentar un resultado sintético como real.

Sección	Qué decía	Qué dice ahora	Por qué cambió
8. Componentes IBM	Descripción conceptual de los siete componentes.	Cada componente se asigna a un módulo del código y se indica si quedó implementado, parcial o sin implementar (sección 9.1).	Requisito de la actividad.
Referencias	Russell y Norvig «(s.f.)»; sin referencias técnicas de la implementación.	Russell y Norvig (2021, 4.ª ed.); se agregan scikit-learn, OpenCV y las fuentes de la matriz de decisión.	Cita incompleta y fuentes nuevas.
Conclusiones	Sección 9.	Sección 10, con los resultados reales de las pruebas.	Numeración exigida por la actividad (sección 9 = Desarrollo).
[Retroalimentación del docente]	[Completar]	[Completar]	[Completar con las correcciones señaladas por el docente]

B. Fase 1 — Selección justificada del agente

El estudiante diseñó dos agentes durante el semestre: **Agente A — FreshCheck-Agent** (clasificación de frutas en una línea de empaque) y **Agente B — RetainIQ-Agent** (predicción de rotación de empleados). La elección se hizo con una matriz de decisión ponderada, con pesos definidos antes de puntuar.

B.1 Criterios y pesos

Se adoptan los seis criterios y los pesos sugeridos por la guía (suman 100 %), porque se ajustan a la rúbrica de la actividad:

Criterio	Peso	Justificación del peso
Viabilidad técnica	25 %	Sin un agente construible no hay nada que demostrar; la implementación vale 25 de 100 puntos de la rúbrica.
Disponibilidad de datos o entorno	20 %	Sin datos o un entorno simulable no hay percepciones ni pruebas posibles.
Medibilidad del desempeño	20 %	La Fase 3 exige probar cada medida con fórmula y umbral; las pruebas valen 20 puntos.
Complejidad de IA	15 %	Interesa que el agente exija razonamiento real, pero la rúbrica evalúa la coherencia con el tipo declarado, no el tipo más alto.
Costo y recursos	10 %	Restricción práctica; ambos agentes se pueden construir con herramientas gratuitas.
Valor del problema	10 %	Pertinencia del problema para un usuario identificable; no condiciona la viabilidad de la entrega.

B.2 Matriz de decisión

Criterio	Peso (w)	A: puntaje (1–5)	A: evidencia (FreshCheck-Agent)	B: puntaje (1–5)	B: evidencia (RetainIQ-Agent)
Viabilidad técnica	25 %	4	5 de 7 componentes IBM con herramientas ya conocidas (Python, pandas, scikit-learn); percepción visual y razonamiento sobre imágenes requieren OpenCV y un simulador de imágenes (5/7 = 0,71).	4	5 de 7 con pandas y scikit-learn; la memoria de trayectorias y la recalibración trimestral exigen series mensuales que el dataset IBM HR (transversal) no trae y habría que simular (5/7 = 0,71).
Disponibilidad de datos o entorno	20 %	4	Dataset concreto identificado (FruitVision) más fotos propias, y entorno simulable con imágenes etiquetadas ilimitadas; falta la banda física.	3	Dataset concreto y descargable (IBM HR, 1.470 empleados), pero transversal y ficticio: no modela el flujo mensual a 3 meses del diseño.
Medibilidad del desempeño	20 %	4	2 de 2 medidas con umbral numérico (exactitud ≥ 95 %, reducción ≥ 30 %); la reducción carecía de línea base y fórmula, que se definen en el ajuste.	3	1 medida con umbral (precisión ≥ 70 %), pero el horizonte de 3 meses y la evaluación trimestral no son verificables sin dimensión temporal; habría que reformularla.
Complejidad de IA	15 %	3	Agente reflejo basado en modelo (R&N) con percepción aprendida y reentrenamiento offline; sin búsqueda, planificación ni función de utilidad.	5	Agente de aprendizaje con elemento de desempeño basado en utilidad y estado interno (trayectorias): cubre tres tipos de la jerarquía de R&N.
Costo y recursos	10 %	5	0 COP: Python, OpenCV y scikit-learn gratuitos, sin APIs de pago, CPU suficiente.	5	0 COP: CSV pequeño y scikit-learn, sin APIs de pago.
Valor del problema	10 %	4	Usuario: personal de calidad de la línea; beneficio: menos unidades defectuosas en el empaque final (contexto piloto hipotético).	4	Usuario: líderes de equipo y RR.HH.; beneficio: anticipar renuncias a 3 meses (el agente solo informa, por restricciones éticas).
Puntaje ponderado S	**100 %**	**3,95**	$S(A) = \Sigma\, w_i \cdot p_i$	**3,85**	$S(B) = \Sigma\, w_i \cdot p_i$

B.3 Cálculo

$S(A) = 0{,}25\times4 + 0{,}20\times4 + 0{,}20\times4 + 0{,}15\times3 + 0{,}10\times5 + 0{,}10\times4 =$ **3,95**

$S(B) = 0{,}25\times4 + 0{,}20\times3 + 0{,}20\times3 + 0{,}15\times5 + 0{,}10\times5 + 0{,}10\times4 =$ **3,85** (puntaje máximo posible: 5)

B.4 Análisis de sensibilidad

El criterio más influyente es **Complejidad de IA** (mayor contribución absoluta a la diferencia, $|w \cdot \Delta p| = 0{,}30$). Se varió el peso de cada criterio en ±10 puntos y se reescalaron proporcionalmente los demás pesos para que sumen 100 %.

Criterio	Cambio de peso	Peso nuevo	S(A)	S(B)	Elegido
Viabilidad técnica	−10 puntos	15 %	3,94	3,83	A
Viabilidad técnica	+10 puntos	35 %	3,96	3,87	A
Disponibilidad de datos o entorno	−10 puntos	10 %	3,94	3,96	B
Disponibilidad de datos o entorno	+10 puntos	30 %	3,96	3,74	A
Medibilidad del desempeño	−10 puntos	10 %	3,94	3,96	B
Medibilidad del desempeño	+10 puntos	30 %	3,96	3,74	A
Complejidad de IA	−10 puntos	5 %	4,06	3,71	A
Complejidad de IA	+10 puntos	25 %	3,84	3,99	B
Costo y recursos	−10 puntos	0 %	3,83	3,72	A
Costo y recursos	+10 puntos	20 %	4,07	3,98	A
Valor del problema	−10 puntos	0 %	3,94	3,83	A
Valor del problema	+10 puntos	20 %	3,96	3,87	A

En el criterio más influyente, el punto de equilibrio está en un peso de 19,1 %: si Complejidad de IA pesara más que eso, RetainIQ-Agent superaría a FreshCheck-Agent.

B.5 Justificación de la elección

Agente elegido: FreshCheck-Agent (A). Puntajes finales: S(A) = 3,95 y S(B) = 3,85 sobre 5. El margen es estrecho (0,10) y se reconoce como tal: la decisión no es robusta ante cualquier cambio de pesos.

Sensibilidad. La decisión se mantiene al variar ±10 puntos Viabilidad, Costo y Valor, y al subir Disponibilidad o Medibilidad. Cambia a favor de B en tres casos: Complejidad con +10 puntos (S(A) = 3,84 frente a S(B) = 3,99) y Disponibilidad o Medibilidad con −10 puntos (3,94 frente a 3,96). Cambia, por tanto, en el criterio más influyente.

Por qué se mantiene la elección. (1) La ventaja de B depende de que la complejidad del tipo de agente pese cerca del 19 %, casi tanto como la medibilidad o la disponibilidad (20 %), lo que contradice el énfasis de la rúbrica en demostrar con pruebas el cumplimiento de las medidas. (2) La medida de B (precisión ≥ 70 % a tres meses con evaluación trimestral) no se puede verificar con el dataset disponible, que no tiene dimensión temporal: exigiría reformularla y simular las trayectorias de los empleados, de modo que sus pruebas serían en buena parte circulares. (3) La medida de A es verificable con etiquetas conocidas y una línea base definible.

Qué se pierde al descartar RetainIQ-Agent. Un agente de mayor complejidad (aprendizaje con elemento de desempeño basado en utilidad y memoria de trayectorias), un dataset tabular real disponible de inmediato (IBM HR Analytics), un menor esfuerzo de percepción (sin visión por computador ni simulador de imágenes) y la oportunidad de trabajar la dimensión ética del tratamiento de datos de personal.

1. Introducción y planteamiento del problema

La inspección manual de frutas en líneas de empaque es lenta, subjetiva y propensa a error humano, lo que permite que unidades dañadas lleguen al empaque final y generen desperdicio, devoluciones y pérdidas económicas. Un agente inteligente basado en visión por computador ejecuta de forma continua y consistente el ciclo de percepción, clasificación y acción sobre cada fruta, tal como lo muestran sistemas de inspección visual en tiempo real reportados en la literatura (Ismail & Malik, 2022). FreshCheck-Agent clasifica frutas según su estado (fresca, en maduración o dañada) en una línea de empaque piloto, con una exactitud mínima de 95 % y una reducción de al menos 30 % en las unidades defectuosas que llegan al empaque final.

Alcance académico. *El diseño apunta a una línea piloto real, pero este trabajo de curso no dispone de una instalación industrial. Por ello el entorno se implementó como un simulador que genera imágenes sintéticas y reproduce las propiedades del ambiente declaradas en la sección 3. FruitVision y las fotografías propias o de internet quedan como la ruta para validar el agente con fruta real (sección 9.8).*

2. Tipo de agente inteligente

FreshCheck-Agent es un **agente reflejo basado en modelo** (Russell & Norvig, 2021). La decisión se justifica por contraste con las demás categorías:

- **No es un agente reflejo simple**, porque este actúa solo sobre el percepto inmediato mediante reglas fijas. Distinguir una maduración normal de un daño real exige un modelo entrenado, y operar con fallas de cámara exige recordar lo ocurrido en cuadros anteriores.
- **Sí es basado en modelo**, porque mantiene un estado interno que se actualiza con cada percepción (*ModeloDelMundo*): color de la banda suavizado en el tiempo, estado de la cámara (OK, degradada, en falla) con histéresis de recuperación, velocidad estimada de la banda y contadores por lote. Ese estado condiciona la decisión: con la cámara en falla, el agente deriva a inspección manual aunque la imagen siguiente parezca válida. Además, el modelo entrenado infiere el estado real de la fruta, que no es observable directamente en el percepto.
- **No es basado en metas**, porque no busca ni planifica secuencias de acciones: cada unidad requiere una decisión de un solo paso.
- **No es basado en utilidad**, porque la acción se deriva directamente de la categoría inferida; no se comparan acciones alternativas con una función de utilidad.

El reentrenamiento periódico con muestras corregidas por el personal de calidad añade un elemento de agente de aprendizaje, pero desacoplado de la operación en línea, que sigue el esquema reflejo basado en modelo. La sección 9.7 incluye una ablación que muestra qué aporta el estado interno y qué no.

3. Tipos de ambiente

Dimensión	Clasificación	Justificación (y alternativa descartada)
Observabilidad	Parcialmente observable	La imagen solo muestra la apariencia externa; el estado real (firmeza, descomposición interna) debe inferirse, y la etiqueta verdadera no viaja en el percepto. Se descarta «totalmente observable».
Determinismo	Estocástico	El simulador introduce aleatoriedad en iluminación (deriva y parpadeo), ruido del sensor, posición, rotación y escala de la fruta, desenfoque, variedad y velocidad de la banda; una misma fruta no produce siempre la misma clasificación. Se descarta «determinista».

Dimensión	Clasificación	Justificación (y alternativa descartada)
Episodicidad	Episódico	Cada imagen se clasifica de forma independiente; la decisión sobre una unidad no depende de las anteriores ni afecta a las siguientes. El estado interno solo gestiona la cámara y los contadores, no condiciona la clasificación de la fruta. Se descarta «secuencial».
Dinamismo	Dinámico	La banda avanza de forma continua, su velocidad tiene deriva aleatoria y el agente dispone de un plazo (distancia ÷ velocidad × 0,8) para decidir antes de que la unidad llegue al desviador; si decide tarde, la unidad pasa de largo. El simulador implementa estas propiedades en tiempo simulado. Se descartan «estático» y «semidinámico».
Discretización	Continuo (acción discreta)	Los valores de píxel y la velocidad varían de forma continua; las salidas son un conjunto finito de tres clases y cuatro acciones. Se descarta «discreto» para la entrada.
Número de agentes	Agente único	Un solo agente percibe, clasifica y decide; el desviador y el personal de calidad no son agentes racionales independientes dentro del ciclo de decisión. Se descarta «multiagente».

4. Descripción del entorno

Actores: unidades de fruta de distintos lotes y proveedores, la cámara sobre la banda, el sistema de control de la banda con su desviador, el personal de calidad y los proveedores. **Restricciones:** plazo de decisión acotado por la velocidad de la banda, tiempo de recarga del desviador, iluminación variable y requisitos de higiene propios de la industria alimentaria. **Condiciones normales:** fruta aislada, centrada y bien iluminada. **Condiciones excepcionales:** iluminación fuera de rango, ruido o desenfoque, frutas en contacto, banda vacía, cámara sin dato, imagen corrupta, alta densidad de unidades y variedades no vistas en el entrenamiento.

5. Entradas y sensores

Entrada	Sensor (entorno real → simulado)	Tipo de señal
Imagen RGB de la fruta	Cámara industrial sobre la banda → imagen sintética generada por el simulador	Matriz 160×160×3, uint8
Señal de disparo	Sensor fotoeléctrico de presencia → bandera del simulador	Binaria
Velocidad de la banda	Encoder del sistema de control → lectura con 2 % de ruido	Numérica continua (m/s)
Lote y proveedor	Lectura de código de barras o QR → campos del lote simulado	Texto

*La etiqueta real de cada fruta **no** es una entrada del agente: el simulador la conserva aparte y solo se usa para calcular las medidas.*

6. Salidas y actuadores

Salida	Actuador o canal	Efecto
Clasificación (fresca, maduración, dañada) con probabilidades	Modelo de visión	Base de la decisión; no modifica el entorno.
Acción DESVIAR	Desviador neumático (InterfazDesviador; en el curso, DesviadorSimulado)	Redirige la unidad dañada al descarte, si llega a tiempo y el desviador está libre.
Acción CONTINUAR	Ninguno	La unidad sigue hacia el empaque final.
Acción REVISION_MANUAL	Derivación a inspección humana	Se aplica ante percepción inválida, cámara en falla o frutas en contacto.

Salida	Actuador o canal	Efecto
Registro y reporte por proveedor	Log CSV y reportes	Historial por lote para los reportes de calidad.

7. Medidas de desempeño

Las medidas se formulan en formato SMART. Los umbrales se fijaron antes de ejecutar las pruebas (archivo config/umbrales.json, SHA-256 1ee072af070e503a…).

Medida	Fórmula	Umbral	Plazo
M1. Exactitud de clasificación	correctas ÷ unidades con fruta única, sin falla inyectada (REVISION_MANUAL y NINGUNA cuentan como error)	≥ 95 % nominal; ≥ 85 % en condiciones límite	Fase de pruebas del curso
M2. Reducción de unidades defectuosas	(D0 − D1) ÷ D0; D0 = dañadas que llegarían al empaque sin agente; D1 = dañadas que llegan con agente	≥ 30 %	Fase de pruebas
M3. Descarte indebido	no dañadas desviadas al descarte ÷ no dañadas	≤ 5 % nominal; ≤ 10 % límite	Fase de pruebas
M4. Latencia de decisión	percentil 95 de la latencia percepción + decisión; número de decisiones fuera de plazo	p95 ≤ 200 ms; 0 tardías	Fase de pruebas
M5. Robustez ante fallas	inyecciones manejadas con la acción y el código esperados, sin excepción y con registro ÷ inyecciones	100 %	Fase de pruebas
M6. Consistencia del reporte por proveedor	celdas iguales entre el reporte del agente y el recalculado desde el log ÷ celdas totales	100 %	Fase de pruebas

Alcanzable. Ismail y Malik (2022) reportan exactitudes de 99,2 % para manzana y 98,6 % para banano con EfficientNet. Estudios con procesamiento de imagen clásico en frutas reales reportan alrededor de 89–92 %, frente a 94–95 % con redes convolucionales (Frontiers of Agricultural Science and Engineering, 2023). Por eso el umbral de 95 % es razonable con un modelo profundo y un conjunto de datos representativo, pero es exigente para un modelo clásico sobre fruta real; en el simulador se evalúa con una dificultad definida de antemano.

Relevante. M1 a M3 miden la calidad de la inspección; M4 y M5 miden la operación en una banda dinámica con fallas; M6 verifica el historial por proveedor que motiva el diseño.

8. Componentes de la arquitectura de IA agéntica (marco IBM)

Los agentes de IA perciben su entorno, deciden y actúan de manera autónoma. IBM describe siete componentes funcionales; la siguiente tabla indica cómo los cubre FreshCheck-Agent (el detalle por módulo está en la sección 9.1).

Componente (IBM)	Cómo lo cubre FreshCheck-Agent
Percepción y manejo de entradas	Valida la imagen, normaliza la iluminación con la banda visible, segmenta la fruta y extrae características.
Planificación y descomposición de tareas	Secuencia fija por unidad: percibir → decidir → actuar → registrar; no requiere planificación deliberativa porque el ambiente es episódico.
Memoria	Corto plazo: estado de la cámara, banda y velocidad. Largo plazo: contadores por lote y log de ejecución.
Razonamiento y toma de decisiones	Modelo entrenado que infiere la clase y regla condición-acción que decide continuar, desviar o derivar.

Componente (IBM)	Cómo lo cubre FreshCheck-Agent
Llamada de herramientas y acción	Interfaz del desviador (simulada en el curso) que recibe la orden con su plazo.
Comunicación	Reporte de calidad por lote y proveedor; interfaz de demostración.
Aprendizaje y adaptación	Reentrenamiento periódico con muestras corregidas por el personal de calidad.

Fuente: IBM, «Components of AI agents», https://www.ibm.com/mx-es/think/topics/components-of-ai-agents

9. Desarrollo del agente

9.1 Arquitectura

El agente se implementó en Python como un paquete (*freshcheck*) con módulos separados para el entorno, la percepción, el modelo, el agente y el actuador. El ciclo percepción → decisión → acción es explícito en *FreshCheckAgent.paso()*, que invoca *percibir()*, *decidir()* y *actuar()*.

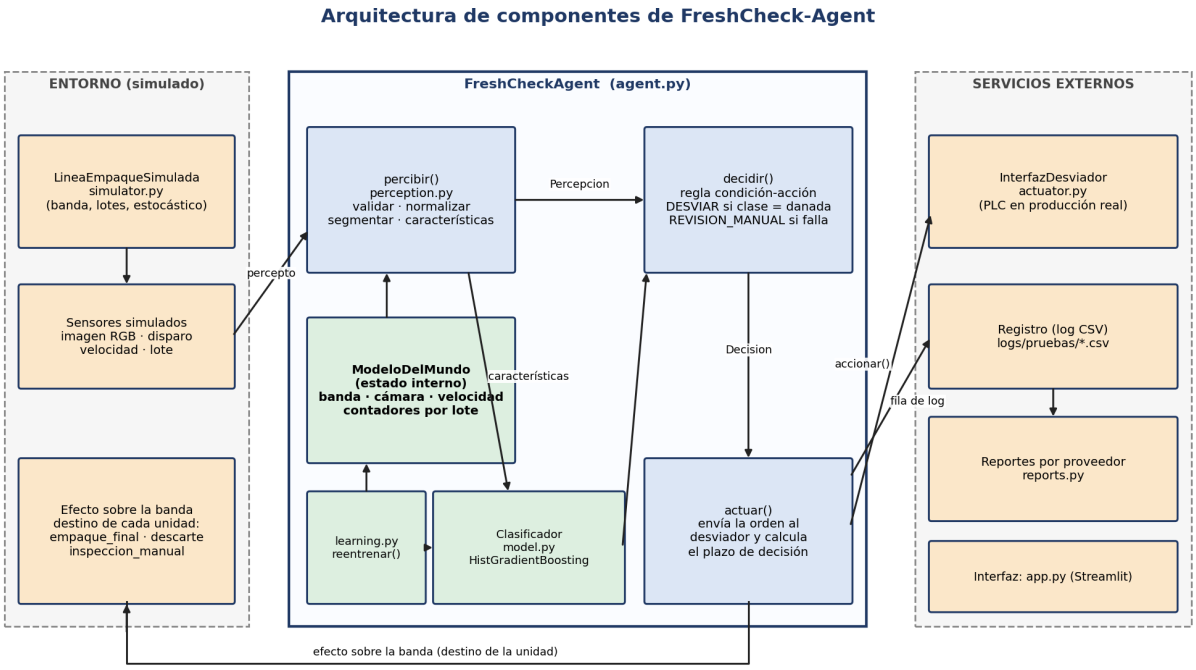


Figura 1. Diagrama de componentes de FreshCheck-Agent.

Componente IBM	Módulo o clase del código	Estado	Observación
Percepción	perception.py (validar_imagen, procesar_imagen); FreshCheckAgent.percibir()	Implementado	Valida, normaliza, segmenta y extrae 38 características.
Planificación	FreshCheckAgent.paso()	Implementado	Pipeline fijo; sin planificación deliberativa, por diseño.
Memoria	ModeloDelMundo; contadores por lote; log CSV	Implementado	Corto plazo en memoria; largo plazo en el log.
Razonamiento	ClasificadorEstado.predecir_proba(); FreshCheckAgent.decidir()	Implementado	Modelo entrenado más reglas condición-acción.
Llamada de herramientas	actuator.py (InterfazDesviador, DesviadorSimulado)	Implementado (simulado)	Sin integración con un PLC real.
Comunicación	reports.py; app.py	Implementado	Reporte por proveedor e interfaz Streamlit.
Aprendizaje	learning.py (RetroalimentacionCalidad, reentrenar)	Parcial	Reentrenamiento manual y offline; la retroalimentación del experimento E2 proviene del simulador, no de personal real.

9.2 Tecnologías

Tecnología	Versión	Para qué se usó	Por qué frente a una alternativa	Quién razona
Python	3.12.3	Lenguaje de todo el sistema	Conocido por el estudiante; ecosistema de IA	—
NumPy	2.4.4	Matrices de imagen y simulación aleatoria	Estándar; base de OpenCV y scikit-learn	Cálculo
OpenCV (headless)	4.13.0.92	Color, segmentación, contornos y componentes conexas	Más rápido y ligero que scikit-image para este pipeline	Código propio sobre OpenCV
scikit-learn	1.8.0	Clasificador HistGradientBoosting	Entrena en minutos en una CPU; frente a una CNN (PyTorch/TensorFlow) exige menos datos y hardware	El modelo aprende el límite entre clases
pandas	3.0.2	Log, reportes y métricas	Agrupaciones y CSV con pocas líneas	Cálculo
joblib	1.5.3	Guardar y cargar el modelo	Recomendado por scikit-learn	—
Matplotlib	3.10.8	Diagramas de arquitectura y secuencia	Sin dependencias externas; frente a PlantUML no requiere Java (se incluyen también las fuentes .puml)	—
Streamlit	1.66.0	Interfaz de demostración y despliegue	Más rápido que Flask para una demo de datos	—
ReportLab	4.4.10	Generación del informe PDF	Reproducible desde el repositorio	—

Uso de modelos de lenguaje. *El agente en ejecución no usa ningún LLM: todo el razonamiento lo realiza el código y el clasificador entrenado. Un asistente de IA (Claude, de Anthropic) se empleó para apoyar el desarrollo del código y del informe, como se declara en la bitácora de uso de IA.*

9.3 Entradas (inputs)

Nombre	Tipo de dato	Rango o formato	Origen	Ejemplo real (log)
imagen	ndarray uint8, BGR	160×160×3; valores 0–255	Sensor simulado (cámara)	brillo medio 65,52; unit_id 0 de N1_nominal_rep0_seed9000
t_s	float	segundos ≥ 0	Reloj simulado	0,5429
velocidad_banda	float	0,05–3,0 m/s; ruido 2 %	Encoder simulado	0,4753
disparo	bool	True/False	Sensor de presencia simulado	True
lot_id, proveedor	str	p. ej. «L-001», «Proveedor A»	Lector de código simulado	L-001, Proveedor A
unit_id	int	≥ 0	Contador del entorno	0
escenario, n_unidades, semilla	str, int, int	13 escenarios; 20–300 unidades	Usuario (CLI o interfaz)	N1_nominal, 200, 9000

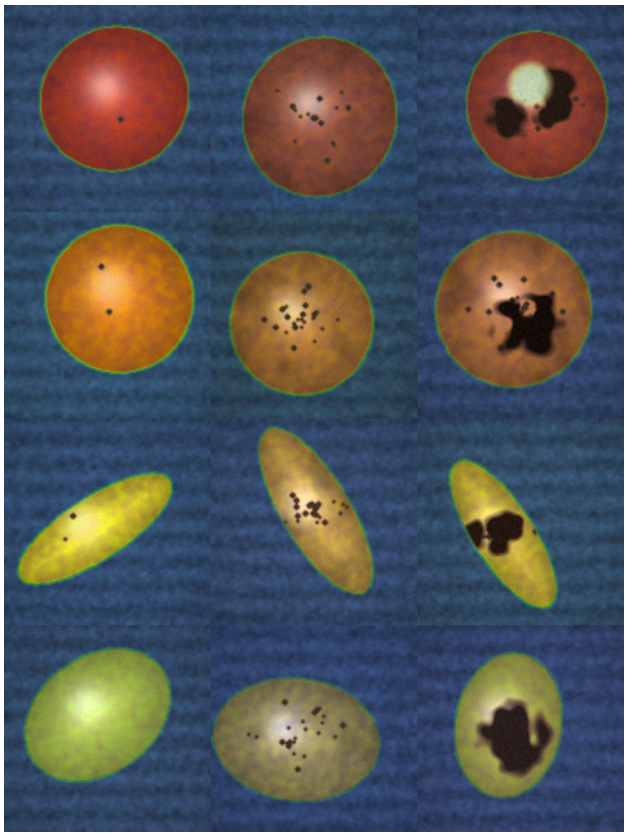


Figura 2. Percepciones generadas por el simulador. Filas: manzana, naranja, banano y pera (esta última no se usa en el entrenamiento). Columnas: fresca, en maduración y dañada.

9.4 Salidas y acciones

Acción	Efecto en el entorno	Ejemplo real (log)
CONTINUAR	La unidad sigue al empaque final.	N1_nominal_rep0_seed9000, unidad 0: fresca (0,9999) → destino empaque_final
DESVIAR	El desviador acciona y la unidad va al descarte; si hay retraso o recarga, pasa al empaque (desvío fallido).	N1_nominal_rep0_seed9000, unidad 8: danada (1,0000) → descarte
REVISION_MANUAL	La unidad se deriva a inspección humana y se registra el motivo.	F01_sin_dato_rep0_seed14000, unidad 10: SENSOR_SIN_DATO → inspeccion_manual
NINGUNA	No hay fruta en la banda; no se actúa.	Escenario F08_banda_vacia: motivo SIN_FRUTA
Registro y reporte	Escribe una fila por unidad y genera el reporte por lote y proveedor.	logs/pruebas/log_clasificacion.csv; reportes_proveedor.csv

9.5 Diagramas de secuencia UML

Se presentan dos escenarios: el típico (clasificación y desvío de una unidad, con los casos de desvío ejecutado y fallido) y uno de excepción (sensor sin dato, cámara en falla y recuperación). Ambos coinciden con los métodos del código; las fuentes PlantUML están en docs/diagramas/.

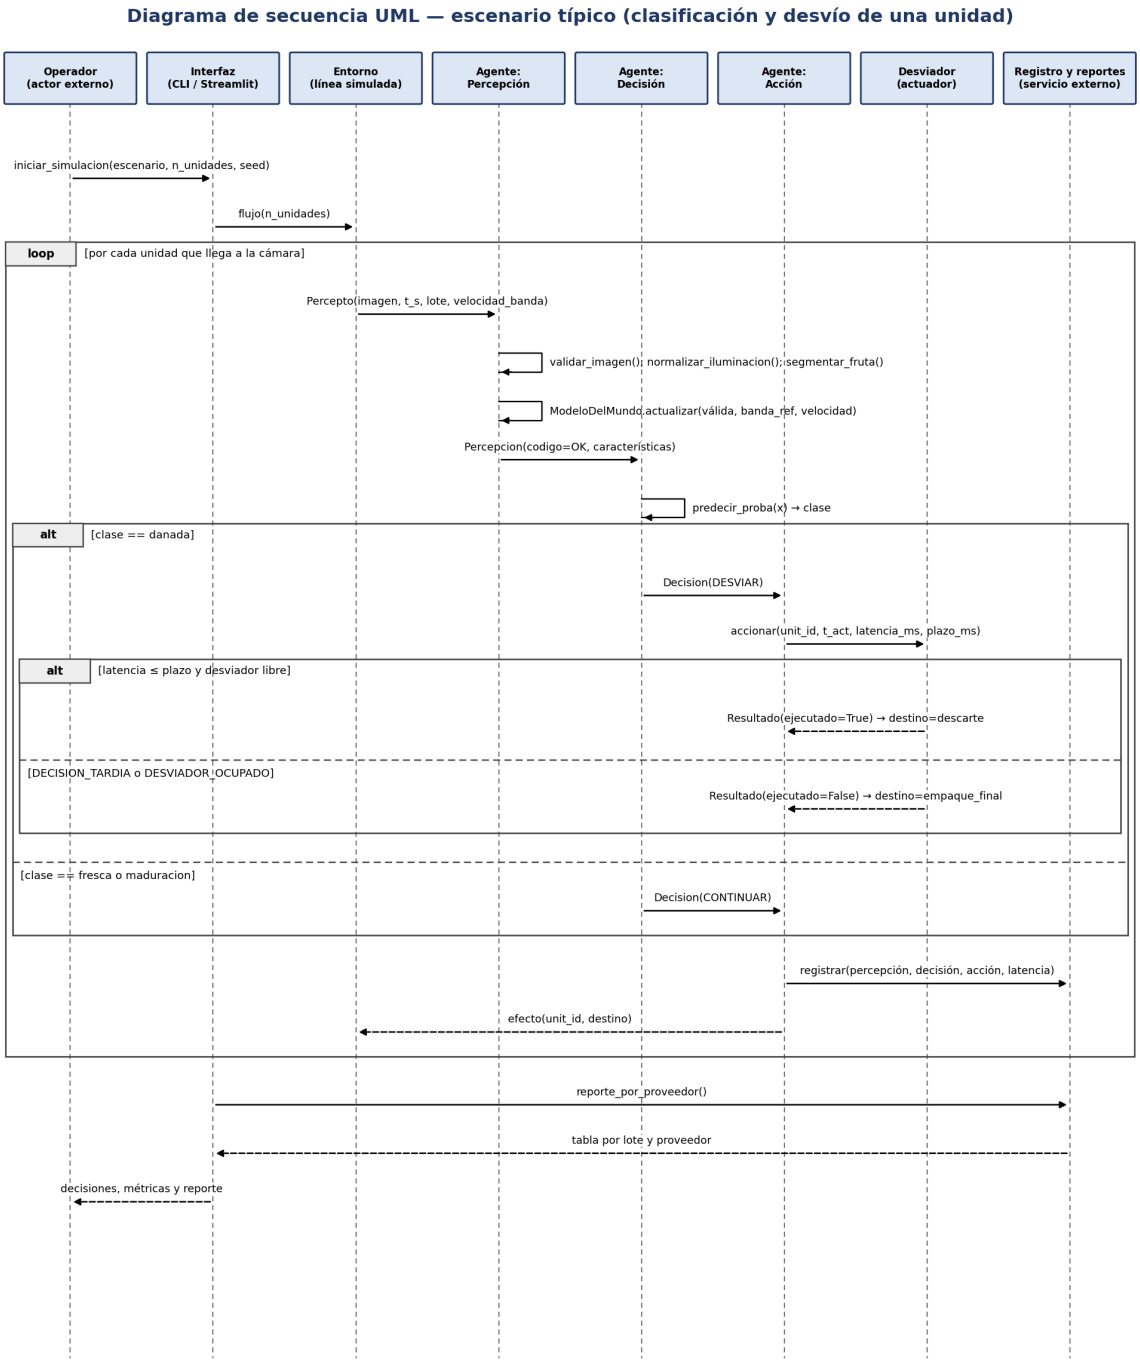


Figura 3. Diagrama de secuencia, escenario típico.

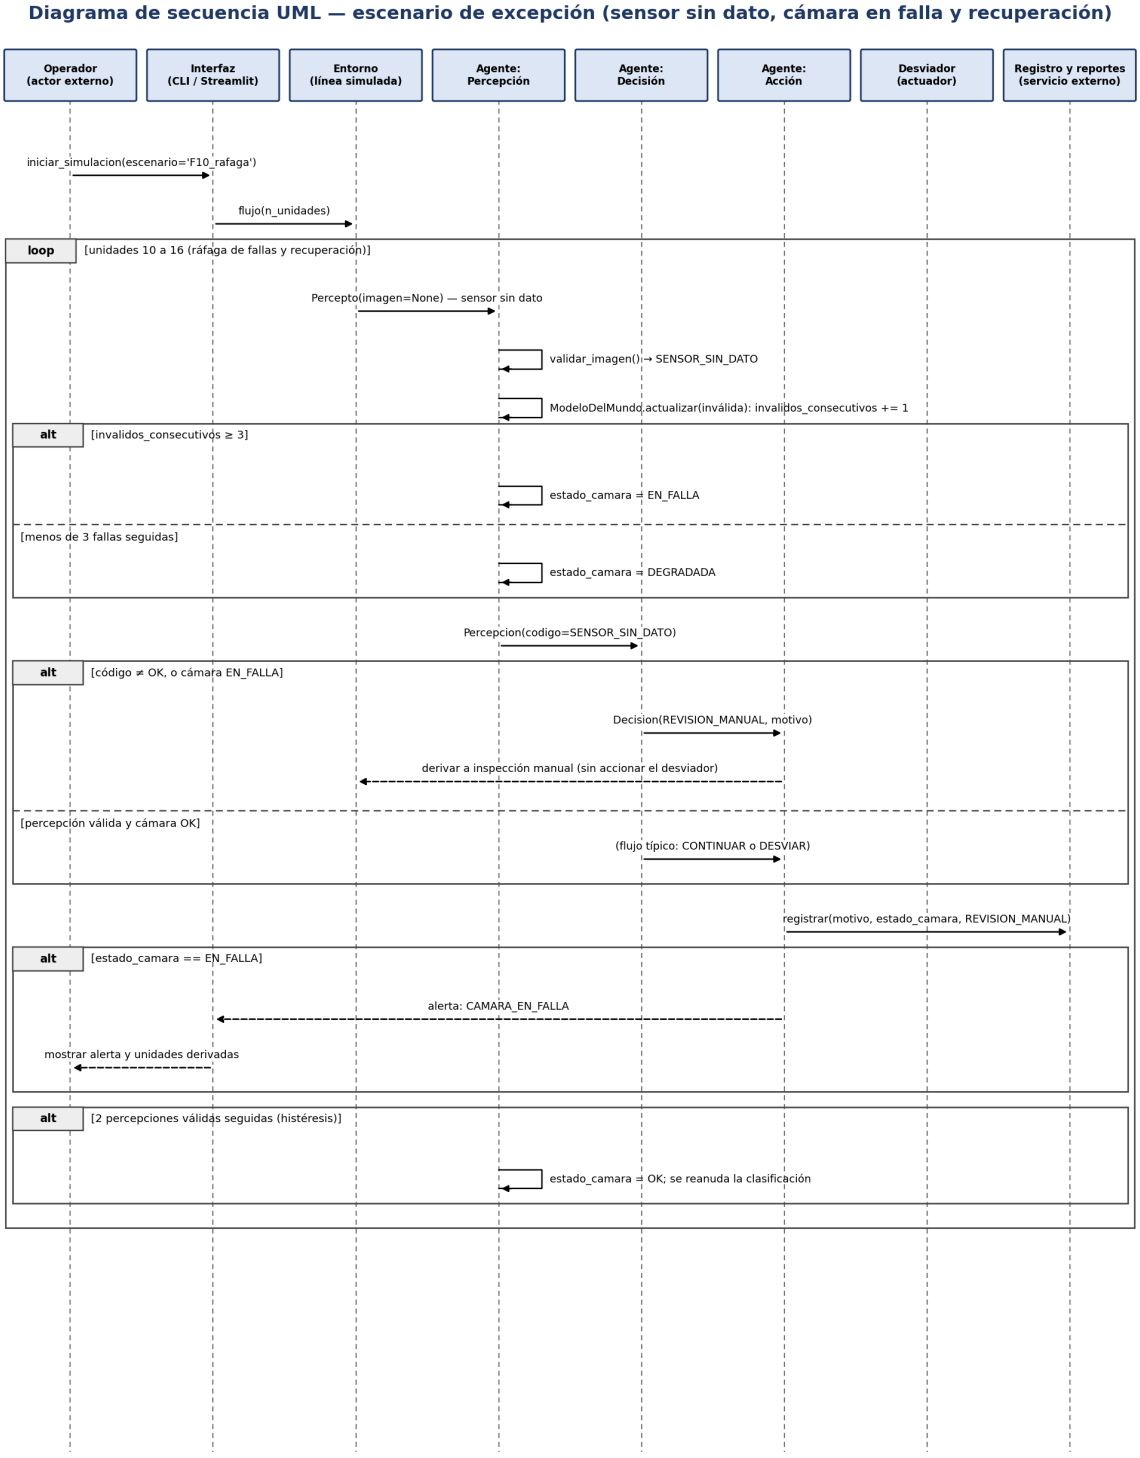


Figura 4. Diagrama de secuencia, escenario de excepción.

9.6 Diferencias entre diseño e implementación

Aspecto	Diseño	Implementación	Justificación
Modelo de visión	Visión por computador entrenada, en la línea de aprendizaje profundo	Características clásicas (color, anomalías, textura) y HistGradientBoosting	Un solo núcleo de CPU, entrenamiento en ~90 s y características interpretables. Contrapartida: la literatura reporta menor exactitud que las CNN en fruta real.
Datos	FruitVision, fotografías propias e imágenes de internet	Imágenes sintéticas del simulador	La guía permite un simulador; los datos reales no se integraron. El script --real-data deja la ruta lista.
Cámara y desviador	Hardware real conectado a la banda	Entorno y actuador simulados con plazo y recarga	No hay instalación industrial.
Acciones	Continuar o desviar	Se agrega REVISION_MANUAL	Acción segura ante percepción inválida o frutas en contacto.
Aprendizaje	Reentrenamiento periódico con corrección del personal de calidad	Reentrenamiento manual y offline	No hay personal real que corrija; se prueba con muestras del simulador (E2).
Estado interno	No definido	ModeloDelMundo	Coherencia con el tipo de agente (ver tabla de cambios).

9.7 Pruebas contra las medidas de desempeño

Todas las medidas se probaron con los umbrales fijados de antemano. Se ejecutaron **13 escenarios de clasificación** (8 nominales y 5 límite) y **11 de falla** (10 dirigidos y 1 de mezcla aleatoria), con **5 repeticiones** por escenario (semillas 9000 en adelante, distintas de las de entrenamiento y validación) y 200 unidades por corrida de clasificación. Como el entorno es estocástico, se reporta la media y la desviación estándar entre corridas (DE).

Medida de desempeño	Fórmula	Umbral	Casos ejecutados	Resultado obtenido	¿Cumple?	Evidencia (log, archivo)
M1. Exactitud (nominal)	correctas ÷ unidades válidas	≥ 95 %	8 escenarios × 5 rep. × 200 = 8.000 unidades	98,78 % (DE 0,63 pp); peor: N5_posicion 98,0 %	**Sí**	log_clasificacion.csv, estrato = nominal; resultados_por_corrida.csv
M1. Exactitud (límite)	igual	≥ 85 %	5 × 5 × 200 = 5.000 unidades	96,10 % (DE 2,40 pp); peor: L4_frontera 92,9 %	**Sí**	log_clasificacion.csv, estrato = limite
M2. Reducción de defectuosas	(D0 − D1) ÷ D0	≥ 30 %	13 × 5 × 200 = 13.000 unidades; D0 = 2.742	98,71 % (DE 3,14 pp); D0 = 2742, D1 = 31; peor: L5_alta_densidad 91,0 %	**Sí**	log_clasificacion.csv (columnas clase_real, destino)
M3. Descarte indebido (nominal)	no dañadas desviadas ÷ no dañadas	≤ 5 %	8.000 unidades	0,08 % (DE 0,21 pp)	**Sí**	log_clasificacion.csv
M3. Descarte indebido (límite)	igual	≤ 10 %	5.000 unidades	0,61 % (DE 0,90 pp); peor: L3_desenfoque 1,83 %	**Sí**	log_clasificacion.csv
M4. Latencia de decisión	p95 de percepción + decisión	≤ 200 ms	13.000 decisiones	p95 = 14,8 ms; máximo 108,2 ms	**Sí**	log_clasificacion.csv (latencia_ms)
M4. Decisiones tardías	latencia > plazo	0	13.000 decisiones	0 tardías	**Sí**	log_clasificacion.csv (tardia)
M5. Robustez ante fallas	manejadas ÷ inyecciones	100 %	11 escenarios × 5 rep.; 199 inyecciones	98,99 % (197 de 199)	**No**	log_fallas.csv; resultados_fallas.csv (columna detalle)
M6. Consistencia del reporte	celdas iguales ÷ celdas	100 %	65 corridas	100,0 %	**Sí**	reportes_proveedor.csv (consistencia_con_agente)

Tabla de resultados obligatoria. Las medidas con dos estratos (M1, M3) y con dos criterios (M4) ocupan una fila por criterio.

Escenarios de prueba

Escenario	Descripción	M1 exactitud (media; DE)	M2 reducción	M3 descarte indebido	p95 (ms)
N1_nominal	Condiciones nominales	98,6 %; 0,22 pp	100,0 %	0,00 %	14,0
N2_luz_baja	Iluminación 20 % menor	99,0 %; 0,00 pp	99,6 %	0,12 %	15,0
N3_luz_alta	Iluminación 25 % mayor	98,6 %; 0,65 pp	99,5 %	0,12 %	14,4
N4_ruido	Ruido alto y desenfoque leve	98,6 %; 0,89 pp	100,0 %	0,00 %	14,7
N5_posicion	Fruta muy desplazada; escala y rotación extremas	98,0 %; 0,35 pp	99,5 %	0,38 %	15,2
N6_banda_lenta	Banda a 0,3 m/s	98,6 %; 0,42 pp	100,0 %	0,00 %	13,8
N7_una_variedad	Lote de una sola variedad (naranja)	99,4 %; 0,42 pp	100,0 %	0,00 %	19,5
N8_lote_critico	Lote con 40 % de fruta dañada	99,4 %; 0,42 pp	100,0 %	0,00 %	14,5
L1_luz_muy_baja	Iluminación al 55 % (fuera del rango de entrenamiento)	98,2 %; 0,67 pp	100,0 %	0,12 %	13,4
L2_sobreexposicion	Iluminación al 155 % (fuera del rango)	96,8 %; 1,04 pp	97,8 %	0,97 %	13,3
L3_desenfoque	Desenfoque fuerte y ruido alto	94,2 %; 1,15 pp	100,0 %	1,83 %	14,6
L4_frontera	Maduración incipiente y daños pequeños (casos fronterizos)	92,9 %; 0,96 pp	96,0 %	0,12 %	13,8
L5_alta_densidad	Banda a 1,5 m/s con unidades muy próximas	98,4 %; 0,82 pp	91,0 %	0,00 %	13,9

Escenarios de falla (M5)

Escenario	Falla inyectada	Inyecciones	Manejadas	Tasa
F01_sin_dato	Sensor sin imagen (None)	15	15	100,0 %
F02_imagen_vacia	Imagen de tamaño cero	15	15	100,0 %
F03_formato	Imagen en escala de grises	15	15	100,0 %
F04_nan	Imagen con valores NaN	15	15	100,0 %
F05_tipo	Cadena de texto en lugar de imagen	15	15	100,0 %
F06_lente_tapado	Imagen completamente oscura	15	15	100,0 %
F07_saturada	Imagen saturada en blanco	15	15	100,0 %
F08_banda_vacia	Disparo con la banda vacía	15	15	100,0 %
F09_solapadas	Dos frutas en contacto	15	13	86,7 %
F10_rafaga	Ráfaga de 5 imágenes sin dato y recuperación	5	5	100,0 %
F11_mezcla	Mezcla aleatoria (12 % de las unidades)	59	59	100,0 %

Experimentos complementarios (no son medidas del diseño)

Escenario	Con modelo del mundo	Sin modelo del mundo (reflejo simple)
N1_nominal	99,4 % (DE 0,9)	99,0 % (DE 0,7)
N2_luz_baja	99,4 % (DE 0,9)	99,6 % (DE 0,5)
L1_luz_muy_baja	98,2 % (DE 1,3)	98,4 % (DE 1,1)
L2_sobreexposicion	95,6 % (DE 0,9)	95,8 % (DE 1,3)

E1 (ablación, 5 repeticiones × 100 unidades). El estado interno no mejora la exactitud de clasificación: las diferencias (menos de un punto porcentual) están dentro de la variación entre corridas. Su aporte se observa en la gestión de fallas: con una ráfaga de cinco cuadros sin dato, el agente con estado marca la cámara «EN_FALLA» y deriva 6 unidades de las 10 a la 16 a inspección manual (incluye el primer cuadro válido tras la falla, por la histéresis de recuperación), mientras que la versión sin estado reporta la cámara «OK» y deriva 5.

E2 (variedad no vista y reentrenamiento). Con la variedad pera, ausente del entrenamiento, la exactitud cae a 46,8 % (DE 4,2). Tras reentrenar con 120 muestras etiquetadas sube a 96,2 % (DE 2,6) y la exactitud nominal se mantiene en 99,6 %. Esto muestra tanto la limitación (variedades nuevas) como el valor del componente de aprendizaje; las muestras provienen del simulador, no de personal de calidad.

Análisis de resultados

Medidas cumplidas. M1 (nominal 98,8 %; límite 96,1 %), M2 (98,7 %), M3 (0,08 % nominal; 0,61 % límite), M4 (p95 de 14,8 ms y ninguna decisión tardía) y M6 (100 %). Sin agente, 21,1 % de las unidades que llegarían al empaque serían dañadas; con el agente, 0,3 %.

Medida incumplida: M5 (98,99 % frente a 100 %). Las 2 inyecciones no manejadas corresponden a F09 (frutas en contacto): en 2 de 15 casos el agente trató la silueta fusionada como una sola fruta y la clasificó (CONTINUAR o DESVIAR) en lugar de derivarla a revisión. *Causa probable:* la regla de detección usa la solidez de la silueta (< 0,94) y, cuando el cuello entre las frutas es poco profundo, la solidez supera el umbral. Bajar el umbral no es gratuito: con la regla actual ya se marcaron como solapamiento 25 de 13.000 unidades válidas (0,19 %), que cuentan como error en M1. *Corrección propuesta:* detectar el contacto con defectos de convexidad del contorno o con una transformada de distancia (watershed), y validar el umbral con un conjunto que incluya frutas aisladas y en contacto.

Otros hallazgos que no incumplen un umbral. (a) En L5 (banda a 1,5 m/s con unidades muy próximas) M2 baja a 91,0 %: 17 de 189 desvíos no se ejecutaron por «DESVIADOR_OCUPADO» (recarga de 60 ms). Correcciones posibles: un segundo desviador, un menor tiempo de recarga o limitar la velocidad de la banda. (b) Los escenarios más bajos de M1 fueron L4 (92,9 %) y L3 (94,2 %); 224 de los errores confunden fresca con maduración (y viceversa), es decir, ocurren en la frontera entre clases, mientras que solo 14 unidades dañadas se clasificaron como no dañadas. (c) La exactitud fuera del rango de iluminación de entrenamiento se mantiene alta (L1 98,2 %; L2 96,8 %); es plausible que la normalización con la banda visible lo explique, pero no se probó por separado.

Cautela de interpretación. Estos resultados provienen de imágenes sintéticas cuya dificultad se fijó antes de las pruebas. Con fruta real cabe esperar una exactitud menor, en línea con las cifras de la visión clásica citadas en la sección 7; el estado interno, además, no mejoró la exactitud en el simulador (E1).

9.8 Limitaciones y trabajo futuro

- **Datos sintéticos.** Validar con FruitVision y fotografías propias: *python scripts/train.py --real-data RUTA* y repetir *run_tests.py* con un simulador reemplazado por el conjunto real.
- **Modelo.** Sustituir las características clásicas por una CNN con transferencia de aprendizaje (por ejemplo EfficientNet o MobileNet), manteniendo el contrato *predecir_proba*.
- **Segmentación.** Asume una banda de color uniforme visible en el borde; con fondos complejos habría que usar detección (por ejemplo YOLO).
- **Frutas en contacto y alta densidad.** Mejorar la detección de contacto (M5) y evaluar un segundo desviador (L5).
- **Hardware.** No se probó con una cámara ni un PLC reales; la interfaz *InterfazDesviador* deja el punto de integración.
- **Aprendizaje.** El reentrenamiento es manual; falta un ciclo con retroalimentación real del personal de calidad y monitoreo de deriva.
- **Medida de reducción.** M2 usa como línea base «sin agente»; una línea base de inspección manual daría una comparación más exigente.

9.9 Enlaces y evidencia de funcionamiento

Elemento	Enlace
Repositorio (README, requirements.txt, código)	[PEGAR ENLACE DEL REPOSITORIO]

Elemento	Enlace
Plataforma de despliegue (Streamlit) o video de máximo 20 minutos	[PEGAR ENLACE]
Logs de las pruebas	logs/pruebas/ (log_clasificacion.csv, log_fallas.csv, resultados_por_corrida.csv, resultados_fallas.csv, reportes_proveedor.csv, resultados_resumen.json, experimentos_extra.json)

10. Conclusiones

FreshCheck-Agent se implementó como un agente reflejo basado en modelo coherente con su diseño: ciclo percepción → decisión → acción explícito, estado interno que condiciona la decisión, ambiente estocástico y dinámico reproducido por el simulador, y los mismos sensores y actuadores del diseño (con las diferencias documentadas en 9.6). En las pruebas se cumplieron las medidas de exactitud, reducción de defectuosas, descarte indebido, latencia y consistencia del reporte, y no se cumplió la robustez ante fallas (98,99 %), por un problema acotado y diagnosticado: la detección de frutas en contacto.

La principal limitación es que la evidencia es sintética. Los resultados demuestran que el agente funciona sobre el entorno simulado y que su arquitectura gestiona fallas y reportes, pero no que alcance el 95 % sobre fruta real; para eso se requiere reentrenar con FruitVision o fotografías propias. La matriz de decisión favoreció a FreshCheck-Agent por un margen estrecho, y el análisis de sensibilidad lo reconoce. Desde el punto de vista operativo, conviene mantener supervisión humana (la acción REVISION_MANUAL) y vigilar el costo de los descartes indebidos.

Referencias

- Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4.ª ed., Global Edition). Pearson.
- IBM. (s. f.). *Components of AI agents*. IBM Think. https://www.ibm.com/mx-es/think/topics/components-of-ai-agents
- Ismail, N., & Malik, O. A. (2022). Real-time visual inspection system for grading fruits using computer vision and deep learning techniques. *Information Processing in Agriculture*, *9*(1), 24–37. https://doi.org/10.1016/j.inpa.2021.01.005
- Machine vision-based automatic fruit quality detection and grading. (2023). *Frontiers of Agricultural Science and Engineering*. https://doi.org/10.15302/J-FASE-2023532
- FruitVision. Conjunto de datos de imágenes de frutas frescas, en descomposición y adulteradas para inspección automatizada de calidad. https://www.sciencedirect.com/science/article/pii/S2352340925004792
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.
- Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*.
- Puertas, E. (2026). *Intelligent Agents* [Material de clase, curso de Inteligencia Artificial]. Universidad Tecnológica de Bolívar.
- IBM HR Analytics Employee Attrition & Performance (Kaggle). https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset

- Employee Attrition Prediction: An Explanatory and Statistically Robust Ensemble Learning Model (MDPI). https://www.mdpi.com/2073-431X/15/3/185

Anexo. Reproducibilidad

Semillas: entrenamiento 1000, validación 2000, pruebas 9000 en adelante. Modelo: 4500 muestras de entrenamiento, exactitud de validación 98,0 %. Umbrales: config/umbrales.json, SHA-256 1ee072af070e503a7cebfe115d74e3481769ec8b0027ade1b56e3bcbcf23cf92. Comandos: *python scripts/train.py*, *python scripts/run_tests.py*, *python scripts/run_extras.py*, *python scripts/decision_matrix.py*, *python scripts/build_informe.py*.